



RAPPORT DE PROJET

(4 pages maximum)

- Remplissez soigneusement les informations ci-dessous.
- Commencez votre travail à la page suivante.
- Sauvegardez votre travail de cette façon :
SCI1402-RapportProjet_Votrenom.docx
- Utilisez l'outil de dépôt des travaux (accessible par votre portail étudiant [MaTÉLUQ](#)) pour acheminer votre travail à la personne responsable de votre encadrement.

Votre prénom et nom : **Gabriel Fleurent-Thiffault**

Votre numéro d'étudiant : **22307023**

Trimestre d'inscription : **Hiver 2025**

Date d'envoi : **30 juin 2025**

Présentation générale du projet

Nom du projet sélectionné

Le projet sélectionné se nomme **UCI Heart Disease Data** (Kaggle, 2025)

Motivation lors de la sélection du projet (pourquoi ce projet)

La motivation derrière la sélection de ce projet était de tenter de confirmer ou de réfuter un mythe souvent évoqué dans mon entourage : plus une personne est âgée et que celle-ci a un haut taux de cholestérol, plus elle a de risques de développer des maladies cardiaques

Définition du projet (en quoi il consiste)

Comprendre et prédire comment les maladies cardiovasculaires peuvent se développer chez les patients, et ce à partir de facteurs déterminés.

Rappel des objectifs visés lors de la sélection du projet

L'objectif principal de ce projet était d'identifier les facteurs significatifs à prendre en compte parmi les 14 attributs donnés, afin de développer un modèle prédictif fiable.

Sans oublier la tâche expérimentale de diagnostiquer et de découvrir d'autres informations qui pourraient aider à mieux comprendre le problème.

Planification du projet (Fournir une liste de tâches en lien avec les objectifs visés, un échéancier sous forme d'un [Gantt](#) incluant chaque tâche et une identification des risques.)

Le diagramme de Gantt est disponible en [annexe A](#), où il est possible de voir l'ensemble des tâches effectuées, la durée estimée, date de début et de fin et les risques potentiels avec leur explication respective.

Également, un visuel représentant l'ensemble des travaux réparti sur 10 semaines.

Pour la création du diagramme, l'inspiration vient grandement du site smartsheet (smartsheet, 2019). Pour en apprendre davantage sur les risques et les diagrammes de Gantt, le site Asana a été bénéfique (Asana, 2025).

Évaluation de la performance de la réalisation (Pour établir des critères pour évaluer la performance de la réalisation de votre projet, vous pouvez consulter le lien suivant : <https://www.inspq.qc.ca/en/node/6352>.)

Pour commencer avec les indicateurs de processus. Afin de calculer l'avancement du projet, l'indicateur d'écart entre l'échéancier planifié et l'exécution des travaux a été sélectionné.

Malgré plusieurs changements en cour de route (ajout de la variation-croisée, adaptation des diagrammes à moustache, etc.), le travail a été exécuté de A à Z, sans perdre l'objectif initial.

Et au niveau des ressources avec l'écart entre nombre d'heures travaillées et planifiées : il y a une grande disparité.

Effectivement, même si la première ébauche faite n'était pas calculée en heures, mais en jours. Il est facile de conclure que l'ampleur du travail avait été grandement sous-estimée et qu'en plus les risques possibles n'avaient aucunement été pris en considération.

Explication des écarts de la réalisation par rapport à la planification

Rappel des résultats réellement atteints avec les objectifs initiaux.

Les travaux ont tous été faits en lien avec l'hypothèse initiale : soit que les personnes âgées ayant un taux élevé de cholestérol sont plus susceptibles de développer des maladies cardiovasculaires.

Avec les résultats connus et une précision de 42.86%, ces deux paramètres à eux seuls ne peuvent expliquer les maladies cardiaques chez les patients.

Donc, devant ce constat, l'objectif principal n'a pas été atteint, puisqu'il n'est pas possible d'identifier les facteurs significatifs permettant d'élaborer un modèle prédictif fort.

En outre, avec ces résultats, il est impossible de répondre à l'objectif *expérimental*, soit de trouver des données pouvant aider à comprendre les maladies du cœur. Étant donnée, qu'aucune piste supplémentaire n'a été trouvée pour expliquer ce type de maladie.

Par contre, avec l'aide du tableau de bord, il y a tout de même une piste à explorer à savoir le genre qui peut avoir une incidence sur le développement de ces maladies.

Bref, une piste de solution non négligeable a exploré dans d'éventuelles recherches.

Justification des choix faits en cours de réalisation :

Approche ou méthodes

L'approche de ce travail avec la régression logistique a été un apprentissage supervisé ; puisque dans ce travail il a été possible d'observer des couples de types entrée-sortie et ainsi d'avoir un modèle permettant d'obtenir des sorties à partir des données reçues à l'entrée.

Ce à partir de l'ensemble « entraînement » (INF 1421, 2024)

Techniques appliquées

- La régression logistique a été choisie, puisque la prédiction escomptée était binaire : avec maladie cardiovasculaire ou non.
- Traitement des données manquantes : Suppression des rangées vides pour **age** et **chol**
- Traitement des données aberrantes : Conserver uniquement les données dans la même mouvance
- Conversions des catégories en valeurs numériques : changer les catégories en valeur numérique
- Évaluation du modèle prédictif de deux manières : précision et la variation croisée
- K-fold : Création de groupes

Outils utilisés

- Python et Jupyter Notebook ont été utilisés afin de concevoir le modèle
- matplotlib.pyplot : Création des diagrammes à moustache
- Sklearn : Pour la création des groupes avec l'aide de K-Fold et pour la variation croisée.
- pyspark.sql, numpy, panda, pyspark.sql.functions (col et when), os, shutil : Des bibliothèques diverses de Python ayant servies à différentes opérations durant les travaux faits via Google Colab.

Énoncé des problèmes rencontrés

À plusieurs reprises, ce qui avait été prévu à la base a dû être modifié au fil que le projet avançait.

Ne pas prendre en considération tous les paramètres (éventuels) dans la planification des tâches.

Aussi, à la première ébauche du travail noté 1, les tâches présentées étaient à mon avis trop générales et donc pas assez granulaires. Effectivement, si nous regardons la tâche « Déploiement du modèle » et bien celle-ci peut être définie en plusieurs sous-tâches.

Conclusion et recommandations

Apprentissage réalisé

Ce que vous feriez différemment si c'était à refaire

Avant même de commencer à programmer, pour éviter de travailler en double, voir en triple. L'information pertinente serait recherchée : fonctions, algorithmes et tout autre renseignement.

Par la suite, les tâches seraient planifiées de manière granulaire. Que ce soit avec la technique agile et un tableau utilisant les cartes kanban ou avec un diagramme de Gantt.

Pour éviter le temps perdu, oui, mais aussi afin de planifier une échéance plus réaliste.

Décrire l'apprentissage le plus significatif

Dans la même voie, de ce qui serait fait différemment, l'apprentissage le plus significatif de ce travail serait de mieux planifier l'ensemble du ou d'un travail.

Effectivement, une habitude de vouloir programmer trop rapidement a été remarquée dans ce projet. Ce même avant d'avoir : établi des fondations solides, pris en compte les risques potentiels.

Dans le monde de la programmation, il y a l'adage : « Think twice, code once », ce qui sera définitivement un concept à ajouter dans mes habitudes de travail à l'avenir.

Annexes

Annexe A | Planification du projet

[illegible]

Annexe B | Journal des activités

(Il s'agit d'une liste des activités réalisées à chaque étape de votre projet. Chaque activité rapportée comprend une date, un nombre d'heures investi et une courte description de l'activité.)

Date	Hr. inv.	Activité réalisée
2025-04-14	2	Comprendre les colonnes et celles importantes
2025-04-15	1	Sélectionner les colonnes importantes
2025-04-17	2	Création d'un répertoire Git Hub et ajout du fichier .csv UCI
2025-04-18	0,5	Création du projet via Google Colab, avec l'ajout d'une application SCI 1402 Projet synthèse.
2025-04-22	1	Ajout du fichier CSV dans l'interface
2025-04-23	2.5	Traitement des données manquantes en supprimant les colonnes vides pour l' age et chol
2025-04-24	2,5	Traitement des données aberrantes, en sélectionnant age et chol
2025-04-25	2,5	Traitement des données aberrantes, en sélectionnant age et chol (Suite)
2025-04-28	3	Création des diagrammes à moustache, pour les deux colonnes sélectionnées précédemment.
2025-04-30	3	Conversion des catégories en valeurs numériques

2025-05-01	1	Conversion des catégories en valeurs numériques (Suite)
2025-05-02	1	Application des filtres (âge supérieur ou égal à 65 et le taux de cholestérol supérieur à 200)
2025-05-02	1,5	Création d'un fichier .CSV unique avec les données filtrées
2025-05-05	3	Création des deux groupes (Test et Entraînement) avec K-Fold
2025-05-06	2	Application et compréhension d'un algorithme d'apprentissage => Régression logistique
2025-05-07	3	Application et compréhension d'un algorithme d'apprentissage => Régression logistique (Suite)
2025-05-09	1	Calculer la précision
2025-05-11	2	Calculer la variation croisée
2025-05-12	2	Calculer la variation croisée (Suite)
2025-05-13	1	Calculer la variation croisée (Suite)
2025-05-13	0,5	Création d'un fichier .CSV à nom unique pour les résultats finaux
2025-05-15	2	Rédaction du travail pratique Rapport mi-parcours
2025-05-18	5	Rédaction du travail pratique Rapport mi-parcours (Suite)
2025-05-20	3	Rédaction du travail pratique Rapport mi-parcours (Suite)
2025-05-22	2	Rédaction du travail pratique Rapport mi-parcours (Suite)

2025-05-26	2	Bonification du Google Colab : Ajout de commentaires, sources supplémentaires, reformulation des imports dans le haut du script.
2025-05-27	2	Bonification du Google Colab : Ajout de commentaires, sources supplémentaires, reformulation des imports dans le haut du script. (Suite)
2025-05-28	2	Bonification du Google Colab : Ajout de commentaires, sources supplémentaires, reformulation des imports dans le haut du script. (Suite)
2025-05-30	4	Révision des diagrammes à moustache, pour qu'ils puissent s'afficher correctement.
2025-06-01	2	Ajustement des deux importations LogisticRegression , pour qu'ils puissent fonctionner ensemble.
2025-06-01	0,5	Création de la branche avec Git Flow via GitHub
2025-06-01	1	Structure des dossiers dans le répertoire GitHub
2025-06-04	1,5	Ajout du readme et de la licence
2025-06-08	4	Gestion et ajout des commits
2025-06-08	1	Rédaction du travail pratique Produit final fonctionnel
2025-06-09	2,5	Rédaction du travail pratique Produit final fonctionnel (Suite)
2025-06-10	0,5	Rédaction du travail pratique Produit final fonctionnel (Suite)
2025-06-12	2	Début du tableau de bord et recherche

2025-06-13	0,5	Création de la table de référence num
2025-06-16	3	Continuation du tableau de bord (Mesure, diagramme et indicateurs) (Suite)
2025-06-18	3	Continuation du tableau de bord (Style et sélection) (Suite)
2025-06-19	1,5	Rédaction de l'explication du tableau de bord
2025-06-20	1,5	Rédaction de l'explication du tableau de bord (Suite)
2025-06-23	3	Rédaction du Rapport du projet présenté
2025-06-25	1	Rédaction du Rapport du projet présenté (Suite)
2025-06-26	4	Rédaction du Rapport du projet présenté (Suite)
2025-06-28	5	Rédaction du Rapport du projet présenté (Suite)
Total	95 heures	

Bibliographie

Asana. (2025, 21 février). Modèle de matrice des risques : évaluer efficacement les risques d'un projet pour assurer sa réussite (exemples inclus). Repéré le 23 juin 2025 à <https://asana.com/fr/resources/risk-matrix-template>

Kaggle. (2025). UCI Heart Disease Data. Repéré le 14 avril 2025 à <https://www.kaggle.com/datasets/redwankarimsony/heart-disease-data>

Smartsheet. (2019, 20 février). *Gantt Chart Templates in Excel and Other Tools*. Repéré le 23 juin 2025 à <https://www.smartsheet.com/gantt-chart-excel-templates>

Université TÉLUQ. (2019). *Module 1 Introduction à l'apprentissage machine*. https://inf1421.teluq.ca/teluqDownload.php?file=2016/09/INF1421-Module1-Introduction_Jan2019.pdf